

3_praktikum

October 17, 2025

```
[1]: import pandas as pd
df = pd.read_csv("data_penjualan.csv")
print(df.head())
```

	nama	umur	gender	qty	price
0	Sari	24.0	M	NaN	9000
1	Hadi	32.0	M	NaN	8000
2	Sari	24.0	F	NaN	15000
3	Xena	21.0	F	5.0	15000
4	Xena	20.0	M	5.0	8000

```
[2]: # Hapus kolom yang tidak diperlukan
df = df.drop(columns=["Unnamed: 0"], errors="ignore")

# Hapus data duplikat
df = df.drop_duplicates()

# Rename kolom
df = df.rename(columns={"qty": "jumlah", "price": "harga"})

print("--- Data setelah rename & drop duplicates ---")
print(df.head())
```

```
--- Data setelah rename & drop duplicates ---
   nama  umur  gender  jumlah  harga
0  Sari  24.0      M     NaN   9000
1  Hadi  32.0      M     NaN   8000
2  Sari  24.0      F     NaN  15000
3  Xena  21.0      F     5.0  15000
4  Xena  20.0      M     5.0   8000
```

```
[3]: #Catat berapa banyak nilai kosong SEBELUM
print("--- Nilai kosong SEBELUM perbaikan ---")
print(df.isnull().sum())

#Hitung rata-rata kolom umur
rata_rata_umur = df["umur"].mean()
print(f"\nRata-rata umur: {rata_rata_umur}")
```

```

#Isi nilai kosong di kolom umur dengan rata-rata
df["umur"] = df["umur"].fillna(rata_rata_umur)

#Isi nilai kosong di kolom jumlah dengan 0
df["jumlah"] = df["jumlah"].fillna(0)

#Isi nilai kosong di kolom harga dengan median
print("\n--- Nilai kosong SESUDAH perbaikan ---")
print(df.isnull().sum())

```

--- Nilai kosong SEBELUM perbaikan ---

```

nama      0
umur      70
gender    0
jumlah    64
harga     0
dtype: int64

```

Rata-rata umur: 26.974025974025974

--- Nilai kosong SESUDAH perbaikan ---

```

nama      0
umur      0
gender    0
jumlah    0
harga     0
dtype: int64

```

```

[4]: # Replace nilai kategorikal
df["gender"] = df["gender"].replace({"M": "Male", "F": "Female"})

# Normalisasi kolom harga
df["harga_norm"] = (df["harga"] - df["harga"].min()) / \
    (df["harga"].max() - df["harga"].min())

# Feature engineering (total_price)
df["total_price"] = df["jumlah"] * df["harga"]

print("--- Data setelah Transformasi ---")
print(df.head())

```

--- Data setelah Transformasi ---

	nama	umur	gender	jumlah	harga	harga_norm	total_price
0	Sari	24.0	Male	0.0	9000	0.4	0.0
1	Hadi	32.0	Male	0.0	8000	0.3	0.0
2	Sari	24.0	Female	0.0	15000	1.0	0.0
3	Xena	21.0	Female	5.0	15000	1.0	75000.0
4	Xena	20.0	Male	5.0	8000	0.3	40000.0

```
[5]: print("\n--- Latihan 1: interpolate() ---")
# Kita baca ulang data mentah untuk demo
df_latihan_1 = pd.read_csv("data_penjualan.csv")

print("Data 'umur' SEBELUM interpolate (baris 0-5):")
print(df_latihan_1[['nama', 'umur']].head())

# Gunakan interpolate()
df_latihan_1['umur'] = df_latihan_1['umur'].interpolate()

print("\nData 'umur' SESUDAH interpolate (baris 0-5):")
print(df_latihan_1[['nama', 'umur']].head())
```

```
--- Latihan 1: interpolate() ---
Data 'umur' SEBELUM interpolate (baris 0-5):
```

	nama	umur
0	Sari	24.0
1	Hadi	32.0
2	Sari	24.0
3	Xena	21.0
4	Xena	20.0

```
Data 'umur' SESUDAH interpolate (baris 0-5):
```

	nama	umur
0	Sari	24.0
1	Hadi	32.0
2	Sari	24.0
3	Xena	21.0
4	Xena	20.0

```
[6]: print("\n--- Latihan 2: describe() Sebelum vs Sesudah ---")

# Sebelum cleaning
df_awal = pd.read_csv("data_penjualan.csv")

print("\n--- Ringkasan Statistik SEBELUM Cleaning (df_awal) ---")
print(df_awal.describe())

# Setelah cleaning
print("\n--- Ringkasan Statistik SESUDAH Cleaning (df) ---")
print(df.describe())

print("\nPerbedaan utama:")
print("- 'count' (jumlah data) di df (sesudah) lebih tinggi untuk 'umur' dan 'jumlah' karena NaN sudah diisi.")
```

```
print("- 'count' total baris di df (159) lebih rendah dari df_awal (163) karena
↳4 baris duplikat dihapus.")
print("- 'mean', 'std', 'min' 'umur' dan 'jumlah' (qty) berubah karena nilai
↳NaN sudah diisi (diisi mean & 0).")
print("- 'df' (sesudah) memiliki kolom baru: 'harga_norm' dan 'total_price'.")
```

--- Latihan 2: describe() Sebelum vs Sesudah ---

--- Ringkasan Statistik SEBELUM Cleaning (df_awal) ---

	umur	qty	price
count	77.000000	85.000000	150.000000
mean	26.974026	2.988235	9353.333333
std	4.463224	1.409949	2912.911933
min	20.000000	1.000000	5000.000000
25%	24.000000	2.000000	7000.000000
50%	27.000000	3.000000	9000.000000
75%	30.000000	4.000000	12000.000000
max	35.000000	5.000000	15000.000000

--- Ringkasan Statistik SESUDAH Cleaning (df) ---

	umur	jumlah	harga	harga_norm	total_price
count	147.000000	147.000000	147.000000	147.000000	147.000000
mean	26.974026	1.673469	9367.346939	0.436735	15877.551020
std	3.220172	1.817583	2935.567511	0.293557	18944.004712
min	20.000000	0.000000	5000.000000	0.000000	0.000000
25%	26.974026	0.000000	7000.000000	0.200000	0.000000
50%	26.974026	1.000000	9000.000000	0.400000	9000.000000
75%	27.000000	3.000000	12000.000000	0.700000	29000.000000
max	35.000000	5.000000	15000.000000	1.000000	75000.000000

Perbedaan utama:

- 'count' (jumlah data) di df (sesudah) lebih tinggi untuk 'umur' dan 'jumlah' karena NaN sudah diisi.
- 'count' total baris di df (159) lebih rendah dari df_awal (163) karena 4 baris duplikat dihapus.
- 'mean', 'std', 'min' 'umur' dan 'jumlah' (qty) berubah karena nilai NaN sudah diisi (diisi mean & 0).
- 'df' (sesudah) memiliki kolom baru: 'harga_norm' dan 'total_price'.