

UJIAN TENGAH SEMESTER (UTS)

MATA KULIAH DATA SCIENCE

Program Studi : Teknik Informatika
Semester/SKS : 7 / 3 SKS
Hari/Tanggal : - / -
Waktu : 2 Pekan
Sifat Ujian : Project Based
Dosen : Yulrio Brianorman

Capaian Pembelajaran yang Diukur:

CPMK	Indikator
CPMK-1	Mahasiswa memahami konsep dasar data science dan ruang lingkungannya
CPMK-2	Mahasiswa mampu melakukan pengumpulan, pembersihan, dan eksplorasi data
CPMK-3	Mahasiswa mampu menerapkan metode statistik dan visualisasi data

Petunjuk Pengerjaan:

1. Berdoalah sebelum mengerjakan project
2. Bentuk kelompok terdiri dari 3-4 mahasiswa
3. Kerjakan semua soal secara sistematis dan kolaboratif
4. Gunakan Python (Jupyter Notebook/Google Colab) untuk analisis data
5. Dataset: *Website Performance Dataset* dari Kaggle
(<https://www.kaggle.com/datasets/maidasajid/website-performance-dataset>)
6. Buat video presentasi dengan durasi 12-15 menit (format MP4, min. 720p)
7. Deliverables yang harus dikumpulkan:
 - File Jupyter Notebook (.pdf)
 - Link Video presentasi kelompok
 - Slide presentasi (PowerPoint/PDF)
 - Laporan kontribusi individu (1-2 halaman per anggota)
8. Format penamaan file: **KelompokXX_NamaDataset_Item**
9. Deadline pengumpulan: 5 Desember 2025 pukul 23:59 WIB
10. Keterlambatan pengumpulan dikenakan penalty -5 poin per hari

BAGIAN A: Data Wrangling dan Exploratory Data Analysis (40 poin)

1. (10 points) Data Wrangling

Lakukan pembersihan data pada *Website Performance Dataset*.

- (a) (4 points) Identifikasi dan tampilkan informasi tentang:
 - Jumlah baris dan kolom
 - Tipe data setiap kolom
 - Missing values pada setiap kolom
 - Duplicate data
- (b) (3 points) Tangani missing values dengan metode yang sesuai (mean imputation, median imputation, atau drop). Jelaskan alasan pemilihan metode untuk setiap variabel.
- (c) (3 points) Deteksi dan tangani outliers pada variabel `response_time` menggunakan metode IQR atau Z-score. Visualisasikan sebelum dan sesudah penanganan outliers menggunakan boxplot.

2. (15 points) Analisis Statistik Deskriptif

Lakukan analisis statistik deskriptif pada dataset yang telah dibersihkan.

- (a) (5 points) Hitung dan tampilkan statistik deskriptif untuk variabel numerik berikut:
 - `response_time`: mean, median, std, min, max, Q1, Q3, P95
 - `throughput`: mean, median, std, min, max
 - `page_load_time`: mean, median, std, min, max
- (b) (5 points) Buat visualisasi distribusi untuk ketiga variabel di atas menggunakan:
 - Histogram dengan KDE (Kernel Density Estimation)
 - Boxplot
- (c) (5 points) Interpretasikan hasil statistik deskriptif dan visualisasi:
 - Apakah distribusi data normal atau skewed?
 - Identifikasi apakah terdapat long tail pada response time
 - Apa implikasi dari distribusi tersebut terhadap user experience?

3. (15 points) Analisis Bivariate dan Multivariate

- (a) (5 points) Buat analisis hubungan antara `response_time` dan `channel` (misalnya: Social Media, Email, Direct):
 - Hitung statistik deskriptif response time untuk setiap channel
 - Visualisasikan dengan boxplot atau violin plot
 - Identifikasi channel mana yang memiliki performa terbaik dan terburuk
- (b) (5 points) Analisis korelasi antar variabel numerik:
 - Hitung correlation matrix
 - Visualisasikan dengan heatmap
 - Identifikasi 3 pasang variabel dengan korelasi tertinggi

(c) (5 points) Buat scatter plot untuk mengeksplorasi hubungan antara:

- `page_load_time` vs `bounce_rate`
- `response_time` vs `conversion_rate`

Interpretasikan pola yang terlihat pada scatter plot.

BAGIAN B: Uji Statistik Hipotesis (40 poin)

4. (20 points) **Perbandingan Rata-Rata (T-Test Sederhana)**

Pilih 2 grup dari dataset untuk dibandingkan. Contoh opsi:

- Bandingkan response time untuk **2 jenis browser** yang berbeda (jika ada kolom `browser`)
- Bandingkan response time untuk **2 lokasi/region** yang berbeda (jika ada kolom `location`)
- Bandingkan response time untuk **2 kategori waktu** (peak hours vs non-peak hours)
- Atau buat kategori sendiri: response time rendah (`< median`) vs tinggi (`>= median`)

Catatan: Sesuaikan dengan kolom yang tersedia di dataset Anda

(a) (5 points) Siapkan data:

- Identifikasi kolom kategorikal yang akan digunakan untuk grouping
- Filter data untuk grup pertama dan grup kedua
- Hitung mean, median, dan standar deviasi response time masing-masing grup
- Tampilkan jumlah sampel di setiap grup

(b) (8 points) Lakukan T-Test:

- H_0 : Rata-rata response time kedua grup sama
- H_1 : Rata-rata response time kedua grup berbeda
- Gunakan fungsi: `from scipy.stats import ttest_ind`
- Code: `ttest_ind(group1_data, group2_data)`
- Catat hasil: t-statistic dan p-value

(c) (4 points) Visualisasi dengan boxplot atau violin plot untuk kedua grup

(d) (3 points) Kesimpulan:

- Jika $p\text{-value} < 0.05$: Ada perbedaan signifikan
- Jika $p\text{-value} \geq 0.05$: Tidak ada perbedaan signifikan
- Grup mana yang memiliki performa lebih baik? Jelaskan!

5. (20 points) **Hubungan Antar Variabel (Correlation)**

Analisis hubungan antara dua variabel numerik di dataset. Contoh pasangan variabel:

- `response_time` vs `throughput`
- `page_size` vs `load_time`
- `number_of_requests` vs `response_time`

Pilih pasangan variabel yang ada di dataset Anda

(a) (5 points) Siapkan data:

- Pilih 2 variabel numerik yang ingin dianalisis hubungannya
- Pastikan tidak ada missing values
- Tampilkan statistik deskriptif keduanya (mean, median, std)

(b) (8 points) Hitung Korelasi:

- H_0 : Tidak ada korelasi antara kedua variabel
- H_1 : Ada korelasi antara kedua variabel
- Gunakan: `df[['var1', 'var2']].corr()`
- Atau: `from scipy.stats import pearsonr`
- Catat nilai correlation coefficient (r) dan p-value

(c) (4 points) Buat scatter plot dengan regression line menggunakan `seaborn.regplot()`

(d) (3 points) Kesimpulan:

- Apakah ada hubungan signifikan? (p-value < 0.05)
- Hubungan positif atau negatif?
- Kuat atau lemah? (lihat panduan di bawah)
- Apa implikasi dari temuan ini untuk optimasi website?

Panduan Mudah Interpretasi:

- P-value < 0.05 = Ada hubungan/perbedaan yang signifikan ✓
- P-value \geq 0.05 = Tidak ada hubungan/perbedaan yang signifikan ✕
- Correlation 0–0.3 = Lemah, 0.3–0.7 = Sedang, 0.7–1.0 = Kuat
- Correlation positif (+) = naik bersama, negatif (–) = berlawanan

BAGIAN C: Analisis Long Tail dan Business Insight (20 poin)

6. (10 points) **Analisis Long Tail Performance**

(a) (4 points) Buat Cumulative Distribution Function (CDF) untuk variabel `response_time`.

(b) (3 points) Identifikasi:

- Persentase pengguna yang mengalami response time di atas 5 detik
- Persentase pengguna yang mengalami response time di atas P95
- Nilai response time pada P50, P90, P95, dan P99

(c) (3 points) Jelaskan dampak long tail response time terhadap user experience dan potensi dampaknya terhadap business metrics.

7. (10 points) **Business Insight dan Rekomendasi**

Berdasarkan hasil EDA dan uji statistik yang telah dilakukan, buat laporan insight dan rekomendasi.

- (a) (6 points) Tuliskan minimal 5 insight penting yang ditemukan dari analisis data, mencakup:
- Insight tentang distribusi response time dan pola performa website
 - Insight tentang perbedaan performa antar grup/kategori yang dianalisis
 - Insight tentang hubungan antar variabel numerik (dari analisis korelasi)
 - Insight tentang outliers dan extreme values dalam data
 - Insight tentang faktor-faktor yang mempengaruhi performa website
- (b) (4 points) Berikan minimal 3 rekomendasi strategis untuk meningkatkan website performance, disertai dengan justifikasi berdasarkan hasil analisis statistik dan visualisasi yang telah dibuat.

Catatan Penilaian:

- Kode Python yang rapi dan terstruktur: 10% dari total nilai
- Visualisasi yang informatif dan mudah dibaca: 15% dari total nilai
- Interpretasi dan analisis yang mendalam: 25% dari total nilai
- Ketepatan metodologi dan hasil uji statistik: 50% dari total nilai

— SELAMAT MENGERJAKAN —